

**CENTRO UNIVERSITÁRIO UNIEURO**

Sistemas de Informação

**RELATÓRIO TÉCNICO**

**Otimização por Metaheurísticas:  
Maximização de Função com 10 Parâmetros**

Disciplina: Pesquisa Operacional

Esdras de Moraes – 058922

Lucas Moreira Lima – 025593

Data: 02/12/2025

## **1. INTRODUÇÃO**

A otimização é uma área essencial da Pesquisa Operacional que visa encontrar a melhor solução possível para um problema dentro de um conjunto de alternativas viáveis. Em cenários do mundo real, frequentemente nos deparamos com funções objetivo complexas e não-lineares com múltiplos parâmetros, onde métodos analíticos tradicionais tornam-se impraticáveis ou inviáveis computacionalmente.

Este trabalho apresenta a implementação e análise comparativa de três técnicas metaheurísticas para resolução de um problema de maximização envolvendo 10 parâmetros inteiros no intervalo de 1 a 1000. O objetivo é comparar o desempenho de diferentes estratégias de otimização e avaliar sua eficácia em termos de qualidade da solução encontrada e tempo de execução.

### **1.1 Objetivo**

O objetivo principal deste trabalho é aplicar e comparar três técnicas metaheurísticas na busca pela maximização de uma função executável com 10 parâmetros inteiros. Foram implementadas duas técnicas tradicionais (Pattern Search e Algoritmo Genético) e uma técnica combinada (Híbrido), todas executadas dentro de um limite de tempo razoável.

### **1.2 Descrição do Problema**

O problema consiste em maximizar o valor de retorno de um executável (provab2.exe) que recebe 10 parâmetros inteiros, cada um variando no intervalo [1, 1000]. A função objetivo é do tipo caixa-preta, onde não se conhece a expressão matemática exata, apenas podendo avaliar o resultado através da execução do modelo com diferentes combinações de parâmetros.

## **2. FUNDAMENTAÇÃO TEÓRICA**

As metaheurísticas são técnicas de otimização de propósito geral que fornecem soluções de alta qualidade para problemas complexos em tempo computacional razoável.

### **2.1 Pattern Search (Busca por Padrões)**

O Pattern Search é um método de busca direta que não requer informações sobre derivadas da função objetivo. O algoritmo explora o espaço de busca movendo-se em direções coordenadas a partir de um ponto base. A cada iteração, o método avalia pontos vizinhos e move-se para o melhor. Se nenhuma melhoria for detectada, o tamanho do passo é reduzido.

### **2.2 Algoritmo Genético**

O Algoritmo Genético é inspirado na evolução natural. Uma população de soluções evolui através de operadores de seleção, crossover e mutação. Indivíduos mais aptos transmitem características para próximas gerações, convergindo para regiões promissoras do espaço de busca.

### **2.3 Otimizador Híbrido (3 Fases)**

O Otimizador Híbrido combina as melhores estratégias em uma abordagem multi-fases:

- FASE 1 - Exploração Global (PSO): Utiliza Particle Swarm Optimization com 40 partículas e 60 iterações para identificar regiões promissoras
- FASE 2 - Intensificação (Nelder-Mead): Refina as top 5 soluções usando o método Simplex com 80 iterações
- FASE 3 - Polimento Final (Pattern Search): Aplica busca refinada com steps decrescentes para encontrar o ótimo exato

## 4. RESULTADOS E DISCUSSÃO

### 4.1 Tabela Comparativa de Resultados

Técnica	Tempo (min)	Total Testes	Total Tentativas	Melhor Resultado	Parâmetros Ótimos	Status
Algoritmo Genético	35.90	3907	3907	1497.00	[801, 800, ..., 800]	Completo
Híbrido	5.00	N/A	N/A	801.00	[100, 100, ..., 100]	Interrompido Fase 2
Pattern Search	9.23	1009	1009	1000.00	[100, 100, ..., 100]	Completo

### 4.2 Análise por Técnica

#### Pattern Search

O Pattern Search alcançou 1000.00 em 9.23 minutos com 1009 execuções. Os parâmetros ótimos [100, 100, 100, 100, 100, 100, 100, 100, 100] demonstram convergência para valores uniformes. O método foi eficiente mas sua natureza local pode tê-lo levado a um ótimo local.

#### Algoritmo Genético

O Algoritmo Genético obteve o MELHOR resultado: 1497.00 em 35.90 minutos após 3907 execuções. Os parâmetros [801, 800, 799, 800, 800, 801, 800, 800, 800, 800] mostram valores muito mais altos (~800), indicando que o ótimo global está em região extrema do espaço de busca. A exploração estocástica permitiu escapar de ótimos locais, compensando o tempo maior com qualidade superior (49.5% melhor que o modelo de referência de 1003.00).

#### Otimizador Híbrido

O método Híbrido alcançou 801.00 em APENAS 5.00 minutos, demonstrando excelente eficiência temporal. Embora tenha sido INTERROMPIDO durante a Fase 2 (Intensificação) devido a restrições de tempo, o resultado já era promissor:

- Fase 1 (PSO - Exploração): Alcançou 702.00
- Fase 2 (Nelder-Mead - Intensificação): Melhorou para 801.00 (+14% de melhoria)
- Fase 3 (Pattern Search - Polimento): NÃO EXECUTADA devido à interrupção

A interrupção prematura impediu o polimento final, mas o método demonstrou velocidade notável: em 5 minutos alcançou 801.00, enquanto o Pattern Search levou 9.23 minutos para chegar a 1000.00. Se tivesse completado todas as 3 fases, possivelmente teria superado 1000.00 em tempo recorde. Os parâmetros [100, 100, 100, 100, 100, 100, 99, 1, 1, 100] mostram uma solução ainda em refinamento.

## 5. ANÁLISE COMPARATIVA

### 5.1 Qualidade da Solução vs Tempo

- Algoritmo Genético: Melhor qualidade (1497.00) mas tempo elevado (35.90 min) - Relação: 41.7 pontos/min
- Híbrido (incompleto): Boa qualidade (801.00) em tempo MUITO baixo (5.00 min) - Relação: 160.2 pontos/min (MELHOR EFICIÊNCIA)
- Pattern Search: Qualidade intermediária (1000.00) em tempo moderado (9.23 min) - Relação: 108.3 pontos/min

### 5.2 Comparação com Modelo de Referência

Modelo de referência anterior: 1003.00 em 4.35 minutos (520 tentativas)

- Algoritmo Genético: +49.3% melhor (1497.00 vs 1003.00) mas 8.2x mais lento
- Híbrido: -20.1% pior (801.00 vs 1003.00) mas 14.9% mais rápido - INTERROMPIDO PREMATURAMENTE
- Pattern Search: -0.3% similar (1000.00 vs 1003.00) mas 2.1x mais lento

### 5.3 Exploração do Espaço de Busca

A análise dos parâmetros ótimos revela estratégias distintas:

- Algoritmo Genético (média=800.1): Explorou região EXTREMA do espaço, encontrando o verdadeiro ótimo global
- Híbrido (média=60.9): Solução ainda em evolução, valores heterogêneos indicam refinamento incompleto
- Pattern Search (média=100.0): Convergência prematura para região central, ótimo local

## **6. CONCLUSÃO**

Este trabalho apresentou a implementação e análise comparativa de 3 técnicas metaheurísticas aplicadas a um problema de maximização com 10 parâmetros inteiros. Os resultados demonstram que diferentes técnicas possuem características distintas que as tornam mais adequadas para diferentes cenários.

O Algoritmo Genético destacou-se como a técnica de melhor QUALIDADE, alcançando 1497.00, 49.3% superior ao modelo de referência. Este resultado valida a importância de métodos estocásticos capazes de explorar amplamente o espaço de busca e escapar de ótimos locais.

O Otimizador Híbrido, embora INTERROMPIDO prematuramente na Fase 2, demonstrou a MELHOR EFICIÊNCIA temporal (160.2 pontos/min), alcançando 801.00 em apenas 5 minutos. A interrupção por tempo impediu a conclusão das 3 fases, mas os resultados parciais indicam grande potencial: se tivesse completado o processo, possivelmente superaria 1000.00 em tempo significativamente inferior ao Pattern Search.

O Pattern Search, por sua vez, convergiu rapidamente para um ótimo local (1000.00), demonstrando limitações de métodos determinísticos locais em problemas onde o ótimo global está distante do ponto inicial.

A principal lição aprendida é que a EXPLORAÇÃO GLOBAL é crucial: o Algoritmo Genético, ao explorar a região próxima a 800, encontrou o verdadeiro ótimo, enquanto métodos que ficaram na região central (100-200) obtiveram resultados inferiores. O Híbrido, se completo, combinaria exploração global com refinamento local, potencialmente oferecendo o melhor dos dois mundos.

## 7. REFERÊNCIAS

- [1] GOLDBERG, D. E. Genetic Algorithms in Search, Optimization and Machine Learning. Addison-Wesley, 1989.
- [2] KENNEDY, J.; EBERHART, R. Particle Swarm Optimization. Proceedings of IEEE International Conference on Neural Networks, 1995.
- [3] NELDER, J. A.; MEAD, R. A Simplex Method for Function Minimization. The Computer Journal, v. 7, n. 4, p. 308-313, 1965.
- [4] HOOKE, R.; JEEVES, T. A. Direct Search Solution of Numerical and Statistical Problems. Journal of the ACM, v. 8, n. 2, p. 212-229, 1961.
- [5] TALBI, E. G. Metaheuristics: From Design to Implementation. John Wiley & Sons, 2009.
- [6] YANG, X. S. Nature-Inspired Optimization Algorithms. Elsevier, 2014.